

Simulación práctica del Teorema Central del Límite (TCL) utilizando el lenguaje de programación Python. (6 marzo)

El objetivo principal es visualizar cómo, al tomar muestras de diversas variables aleatorias, la distribución de sus medias tiende a seguir una distribución normal o "Campana de Gauss", independientemente de la distribución original de los datos.

- Concepto Fundamental del Teorema

El teorema establece que si se toman muestras de un tamaño determinado de una población con media y varianza finitas, y luego se calcula la media de esas muestras, el histograma resultante representará una normalidad universal.

- Metodología de la Simulación en Python

Se utilizan herramientas como NumPy y Pandas para recrear este fenómeno estadístico:

- Generación de datos: Se crean muestras utilizando variables aleatorias Binomiales. Por ejemplo, simula lanzar 1,000 monedas con una probabilidad de éxito de 0.6.
- Organización en DataFrames: Se utiliza un ciclo `for` para generar múltiples muestras (por ejemplo, 100 muestras de 50 elementos cada una) y almacenarlas en una estructura de datos organizada por columnas.
- Cálculo de la media: El paso crucial es calcular la media de cada una de las muestras obtenidas, creando un nuevo conjunto de datos que represente estas medias.

3. Visualización y Universalidad

Para confirmar el teorema, se emplean herramientas gráficas como Seaborn para generar histogramas y diagramas de distribución (`distplot`).

- Resultados: A pesar de que los datos iniciales provienen de lanzamientos de monedas (ceros y unos), el histograma de sus medias muestra claramente la forma de la campana de Gauss.
- Independencia de la distribución: Este resultado no es exclusivo de las variables binomiales. Al repetir el experimento con variables exponenciales o uniformes, se observa el mismo patrón de aproximación a la normalidad.

INTRODUCCION A ESTADISTICA BAYESIANA (8 marzo)

1. Comparación de Paradigmas

La principal diferencia identificada reside en la concepción de la probabilidad y los parámetros:

Enfoque Frecuentista: Define la probabilidad como un límite de frecuencias relativas y trata los parámetros como constantes fijas y desconocidas.

Enfoque Bayesiano: Considera la probabilidad como un grado de creencia o certidumbre. Esto permite realizar afirmaciones probabilísticas directamente sobre los parámetros, tratándolos como variables aleatorias con distribuciones propias.

2. El Proceso de Inferencia y la Regla de Bayes

El núcleo de la estadística bayesiana es la actualización de creencias mediante la Regla de Bayes: $p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$. Los componentes fundamentales identificados son:

Distribución Inicial (Prior): Refleja el conocimiento o creencia previa sobre el parámetro θ antes de observar los datos.

Verosimilitud (Likelihood): Resume la información que los datos observados aportan sobre el parámetro.

Distribución Posterior: Es el resultado de combinar la información previa con los datos; representa nuestra certidumbre actualizada.

3. Métodos de Cálculo y Simulación

Debido a la complejidad de calcular la "evidencia" (el denominador de la regla de Bayes), se detallan tres rutas principales:

Distribuciones Conjugadas: Se utilizan cuando la distribución inicial y la posterior pertenecen a la misma familia (ej. Beta-Bernoulli o Normal-Gamma Inversa), lo que permite soluciones analíticas directas.

Aproximación por Cuadrícula: Útil para modelos sencillos con pocos parámetros.

Métodos MCMC (Cadenas de Markov vía Monte Carlo): Son algoritmos de simulación esenciales para modelos complejos.

Algoritmo de Metrópolis: Genera una caminata aleatoria para explorar la distribución objetivo.

Muestreador de Gibbs: Más eficiente para múltiples parámetros, ya que simula valores a partir de las distribuciones condicionales de cada uno.

4. Modelado Jerárquico y Herramientas

El artículo destaca los modelos jerárquicos, donde los parámetros dependen de otros niveles (hiperparámetros), permitiendo modelar dependencias complejas como monedas producidas por una misma fábrica.

Para la implementación práctica, se recomienda el uso de JAGS (Just Another Gibbs Sampler), un software que facilita el ajuste de modelos especificando solo la verosimilitud y las iniciales.

5. Diagnósticos de Calidad

Finalmente, se recalca que cualquier inferencia basada en MCMC debe validarse mediante:

Factor de reducción potencial de escala ($\hat{R}$): Debe ser ≤ 1.1 para asegurar que las cadenas han convergido.

Número efectivo de simulaciones (n.eff): Se recomienda que sea de al menos 100 para garantizar que la muestra sea representativa.